UNIVERSIDADE FEDERAL RURAL DO SEMI-ÁRIDO
CENTRO MULTIDISCIPLINAR DE PAU DOS FERROS
ENGENHARIA DA COMPUTAÇÃO
PROFESSOR DR. PEDRO THIAGO VALÉRIO DE SOUZA
SISTEMAS INTELIGENTES

THIAGO GEOVANE DA COSTA NUNES

PROJETO 1: MODELO DE REGRESSÃO LOGÍSTICA

PAU DOS FERROS – RN
2026

Sumário

1.INTRODUÇÃO.....3

2. METODOLOGIA.....3

3. RESULTADOS E DISCUSSÕES.....4

4. CONCLUSÃO.....6

ANEXO I.....7

ANEXO II.....7

1.INTRODUÇÃO

Repositório: https://github.com/Rated84/projeto02_regress-ologistica.git

Este trabalho tem como objetivo desenvolver um modelo de classificação utilizando regressão logística para prever a presença de doença cardíaca com base em variáveis clínicas de pacientes.

As variáveis utilizadas foram:

- **age** — idade do paciente em anos;
- **sex** — sexo biológico (1 = masculino, 0 = feminino);
- **cp** — tipo de dor no peito: angina típica (1), atípica (2), não anginosa (3) ou assintomático (4);
- **trestbps** — pressão arterial em repouso em mmHg;
- **chol** — colesterol sérico total em mg/dl;
- **fbs** — glicemia em jejum acima de 120 mg/dl (1 = sim, 0 = não);
- **restecg** — resultado do ECG em repouso: normal (0), alteração na onda ST-T (1) ou hipertrofia ventricular (2);
- **halach** — frequência cardíaca máxima atingida no teste de esforço;
- **exang** — angina induzida por exercício (1 = sim, 0 = não);
- **oldpeak** — depressão do segmento ST durante o esforço, indicador de isquemia;
- **slope** — inclinação do segmento ST no pico do esforço: ascendente (1), plano (2) ou descendente (3);
- **ca** — número de artérias coronárias com obstrução visível na fluoroscopia (0 a 3);
- **thal** — cintilografia de tálio: normal (3), defeito fixo / infarto prévio (6) ou defeito reversível / isquemia ativa (7);

2. METODOLOGIA

Para treino do modelo foi utilizado o utilizamos o dataset UCI CCPP (disponível em https://archive.ics.uci.edu/dataset/45/heart+disease), disponibilizado pelo UCI Machine Learning Repository, contendo informações de 303 pacientes com 13 variáveis clínicas.

Primeiramente, foi do dataset, o que permitiu o acesso direto aos registros clínicos dos pacientes. Em seguida, foi condizida uma etapa de pré-processamento dos dados, com o objetivo de garantir sua qualidade e adequação ao modelo. Nessa etapa, foram identificados valores ausentes nas variáveis *ca* e *thal*, os quais foram tratados por meio de imputação pela mediana, método escolhido por sua robustez a valores extremos.

Em seguida, a variável alvo original (num), que apresentava valores entre 0 e 4 indicando diferentes níveis de severidade da doença, foi binarizada em uma variável categórica, sendo 0 representando ausência de doença e 1 representando presença de doença. Posteriormente, o conjunto de dados foi particionado em dois subconjuntos: 80% destinados ao treinamento do modelo e 20% reservados para teste, utilizando estratificação para preservar a proporção entre as classes.

Posteriormente, as variáveis numéricas contínuas (*age, trestbps, chol, thalach* e *oldpeak*) foram padronizadas por meio do *StandardScaler*, garantindo média zero e desvio padrão unitário, o que contribui para a estabilidade e eficiência do processo de treinamento.

3. RESULTADOS E DISCUSSÕES

No presente tópico segue a análise dos dados e respostas das questões pedidas pelo docente.

Tabela 1 – head()

	age	sex	cp	trestbps	chol	fbs	restecg	thalach	exang	oldpeak	slope	ca	thal	num
0	63	1	1	145	233	1	2	150	0	2.3	3	0.0	6.0	0
1	67	1	4	160	286	0	2	108	1	1.5	2	3.0	3.0	2
2	67	1	4	120	229	0	2	129	1	2.6	2	2.0	7.0	1
3	37	1	3	130	250	0	0	187	0	3.5	3	0.0	3.0	0
4	41	0	2	130	204	0	2	172	0	1.4	1	0.0	3.0	0

1 No pré-processamento:

(a) Realize o tratamento de valores nulos (verificar especialmente as colunas ca e thal). Caso existam, escolha o método de imputação através da mediana.

(b) Obtenha a binarização da variável target, transformando os valores originais (0 a 4) em uma variável binária (0 = sem doença, 1 = com doença).

Foi seguido uma regra de que valores 0 seriam sem doença e valores maiores que 0 com doença, ou seja:

0 → sem doença (0)

<0 → com doença (1)

(c) Realize a divisão treino/teste com proporção de 80/20, usando stratify = y para preservar o balanceamento entre as classes.

(d) Faça o escalonamento das features numéricas contínuas (age, trestbps, chol, thalach, oldpeak) com StandardScaler.

2 Treinar um modelo de LogisticRegression do scikit-learn utilizando os dados de treino, com os seguintes parâmetros: solver='liblinear', random state=42 e max iter=1000. Indique quantas iterações foram necessárias para a convergência do modelo.

Como é mostrado no anexo 1, foram necessárias 5 interações para a convergência do modelo.

3 Avaliar o modelo utilizando os dados de teste e calcular as seguintes métricas:

(a) Acurácia.

(b) Precisão.

(c) Recall.

(d) F1-score.

(e) Curva ROC com valor de AUC: anexoII

Tabela 2 - métricas

Métricas	
Acurácia	0.8689
Precisão	0.8125
Recall	0.9286
F1-score	0.8667
AUC	0.9545

4. CONCLUSÃO

O modelo de regressão logística desenvolvido demonstrou desempenho sólido na tarefa de classificação de doença cardíaca, alcançando acurácia de 86,89%, recall de 92,86% e AUC de 0,9545. Esses resultados evidenciam a alta capacidade do modelo em distinguir pacientes com e sem a doença, com destaque para o elevado recall, métrica especialmente relevante em contextos médicos por reduzir a ocorrência de falsos negativos.

A rápida convergência do modelo, atingida em apenas 5 iterações, indica que o pré-processamento adotado — incluindo imputação de valores ausentes pela mediana, padronização das variáveis com StandardScaler e binarização adequada da variável alvo — foi eficaz na preparação dos dados, contribuindo para a estabilidade e eficiência do treinamento.

Além disso, a análise dos coeficientes do modelo permitiu identificar variáveis clinicamente relevantes, como o número de artérias coronárias obstruídas (*ca*), o sexo (*sex*) e a presença de angina induzida por exercício (*exang*), reforçando a coerência dos resultados com o conhecimento médico.

Apesar dos bons resultados, o modelo apresenta limitações inerentes à regressão logística, como a suposição de relações lineares entre as variáveis e a dificuldade em capturar interações mais complexas. Nesse sentido, trabalhos futuros podem explorar modelos mais sofisticados, como Random Forest e Gradient Boosting, além do uso de técnicas de validação cruzada e seleção de atributos, visando obter estimativas ainda mais robustas.

Em síntese, o modelo desenvolvido mostra-se adequado como ferramenta de apoio à decisão médica, podendo ser utilizado como um mecanismo de triagem inicial para estimar o risco cardiovascular de pacientes a partir de dados clínicos simples, com potencial real de aplicação prática.

ANEXO I

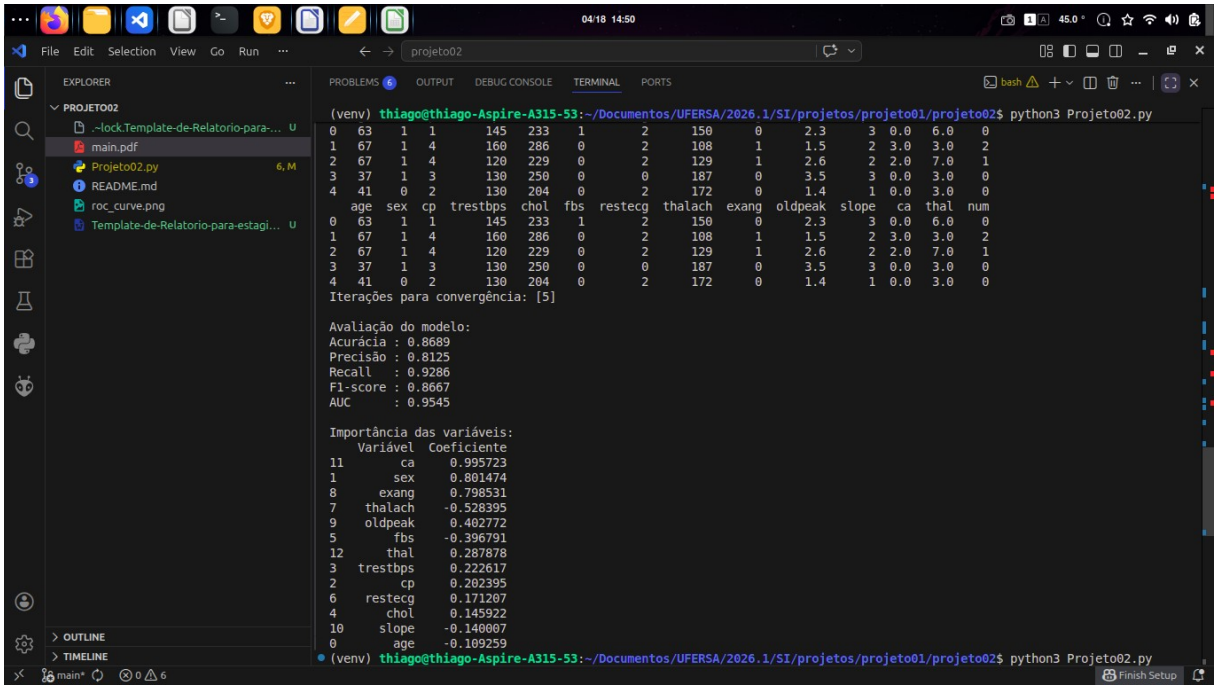
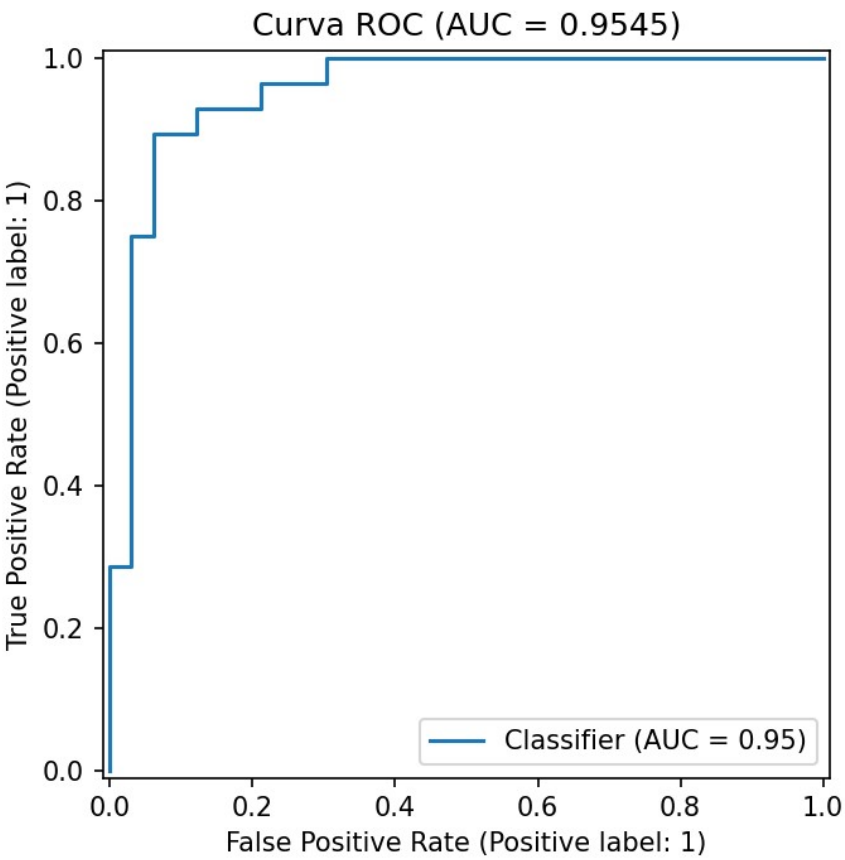
ANEXO II